Türkçe Emsal Karar Atıflarında Destekleme Doğruluğu: Uzman Etiketli Veri Seti ve Kanıta Dayalı Seçici Doğrulama — Revize Proje Önerisi

Bitirme Projesi ve TÜBİTAK 2209-A · Proje kısa adı: Dilekçe Atıf Denetçisi · Umut Şahin, Bilişim Sistemleri Mühendisliği, Kocaeli Üniversitesi · Nov 2, 2026 · @Umut ŞAHİN

Revizyon özeti

Öneri, danışman geri bildirimindeki 16 madde ve kaynak doğrulama uyarısı doğrultusunda baştan düzenlendi. Proje artık bir araç geliştirme çalışması olarak değil, Türkçe Yargıtay kararlarında **iddia düzeyinde destek doğrulaması** üzerine bir araştırma olarak kurgulanmıştır.

2 Kasım 2026 revizyonu. Hukuk fakültesi öğretim üyesi, Türkiye'de benzer ticari araçların bulunduğunu (ör. Sinerji) ve özgünlük araştırmasının eksik kaldığını belirtmiştir. Bu nedenle özgünlük iddiası yeniden kurulmuştur: proje atıfları denetleyen bir araç değil, bu denetimin Türkçede ne kadar güvenilir yapılabildiğini ölçen bir araştırmadır. Ana çıktılar uzman etiketli bir test seti, mevcut yaklaşımların bu sette ilk ölçümü ve yanlış desteklemeyi azaltan bir yöntemdir (KSD). Ticari ürünlerin ve Türkçe değerlendirme çalışmalarının taraması Bölüm 2'ye eklenmiştir.

Bu sürüm ara revizyondur. 19 Ekim 2026 güncellemesinde literatür tablosu ve kaynakça, çalışmaların tam metinleri ve resmî sayfalarıyla karşılaştırılarak düzeltilmiştir. Pilot çalışmanın sonuçları ve kalan kaynakların incelemesi tamamlandığında güncellenmiş sürüm sunulacaktır.

Madde	Geri bildirim	Karşılandığı bölüm
1	Literatür taraması ve benzer çalışmalarla karşılaştırma	2
2	Özgün bilimsel katkı	3
3	Kapsamın daraltılması	4
4	Araştırma soruları ve hipotezler	5
5	Veri kaynakları ve erişim koşulları	6
6	Veri seti oluşturma yöntemi	7

Madde	Geri bildirim	Karşılandığı bölüm
7	Etiketleme ve uzman doğrulaması	7
8	İddia–kanıt tutarlılığının belirlenmesi	8
9	Yapay zekâ modelleri ve yöntemler	8
10	Özgün doğrulama mekanizması	9
11	Karşılaştırmalı deneyler	10
12	Sayısal başarı kriterleri	10
13	Deneylerin güvenilirliği	10
14	İş paketleri ve zaman planı	11
15	Risk yönetimi	12
16	2209-A önerisinin güncellenmesi	Tüm belge
Ek	Kaynakların gerçekliğinin doğrulanması	14
Ek 2	Benzer ticari araçlar ve özgünlük araştırması (hukuk danışmanı)	2, 3

1. Problem ve gerekçe

Dilekçelerde atıf yapılan bir emsal kararın gerçekten var olması yetmez; kararın, dilekçedeki iddiayı gerçekten desteklemesi gerekir. Yapay zekâ destekli yazım araçları yaygınlaştıkça hem var olmayan kararlara hem de iddiayı desteklemeyen gerçek kararlara atıf yapılması riski artmaktadır.

Literatür, ikinci türün daha zor olduğunu gösteriyor. PARCEL çalışmasında en güçlü dil modelleri bile karar metninin tamamı verildiğinde desteklenmeyen iddiaları "desteklenmiş" olarak işaretleyebilmiş; en zor durum kanıtın *yokluğunu* fark etmek olmuştur (bkz. Bölüm 2).

Türk hukuk pratiğinde bu kontrol hâlâ büyük ölçüde avukatın atıf yaptığı kararı açıp iddiayla elle karşılaştırmasına dayanır. Öte yandan Türkiye'de içtihat araması ve dilekçe taslağı üreten yapay zekâ destekli ticari araçlar hızla yaygınlaşmaktadır (Bölüm 2). Bu araçlar yüksek doğruluk iddia etse de, atıf yapılan kararın iddiayı gerçekten destekleyip desteklemediğini ne sıklıkla doğru belirledikleri, bağımsız ve tekrarlanabilir bir test setiyle ölçülmemiştir.

Bu proje bu ölçüm boşluğunu hedefler: Türkçe Yargıtay kararları için uzman etiketli bir test seti kurar, yaygın yaklaşımların **yanlış "destekliyor" kararı verme sıklığını** ilk kez ölçer ve bu hatayı azaltan bir yöntem önerir.

Atfın yalnızca var olup olmadığını kontrol etmek de yeterli değildir. Çince hukuk raporları üzerinde yapılan LegalCiteTrust çalışmasında, var olmayan atıflar ayıklandığında kalan karar atıflarının sadakat ve uygulanabilirlik puanları düşmüştür (bkz. Bölüm 2). Bu bulgu, varlık kontrolünün destek kontrolünün yerini tutamayacağını göstermektedir.

- [ ] Türkiye'den bir olay örneği eklenecekse yalnızca resmî veya birincil kaynağı açılıp doğrulanarak eklenecek.

2. Literatür ve benzer çalışmalar

En yakın çalışma PARCEL'dir; ancak İngilizce ve ABD hukuku üzerindedir ve yanlış desteklemeyi azaltan bir yöntem önermez. LegalCiteTrust, Çince raporlarda atıfların uygulanabilirliğini değerlendirir ve doğrulama sonuçlarını yapay zekâya geri bildirerek raporu yeniden yazdıran bir revizyon yöntemi dener; ancak rapor düzeyinde çalışır, çoğunlukla mevzuat atıflarına dayanır ve belirsizlik durumunda çekimser kalma içermez. Türkçe tarafta TurkishLegalBench kanun ve madde atfı çıkarma ile karar içi tutarlılık görevleri içerir, fakat dilekçedeki bir iddianın atıf yapılan kararla desteklenip desteklenmediğini sınamaz.

Çalışma	Dil / hukuk	Görev	Kanıt metni verili mi	"Yetersiz kanıt" sınıfı	Yanlış desteklemeyi azaltma
PARCEL (Demir ve Canbaz, ICAIL 2026)	İngilizce, New York	İddia–karar doğrulaması, 3 sınıf (Supported / Refuted / Not Found), 3.396 iddia	Evet, kararın tam metni	Var	Yok; yalnızca zero-shot LLM değerlendirmesi. Belirsizlik farkındalığı ve doğrulayıcı/ensemble yöntemleri gelecek çalışma olarak önerilmiş

Çalışma	Dil / hukuk	Görev	Kanıt metni verili mi	"Yetersiz kanıt" sınıfı	Yanlış desteklemeyi azaltma
LegalCiteBench (Chen, Yin ve Zhou, AI4Law @ ICML 2026)	İngilizce, ABD	5 görev, yaklaşık 24 bin örnek: atıf hatırlama, tamamlama, hata tespiti, karar eşleştirme ve doğrulama. Cat4-2'de kararın bir ilkeyi destekleyip desteklemediği sorulur; yanlış örnekler rastgele karar değişimiyle üretilmiştir	Hayır (closed-book)	Yok	Yalnızca istemle çekimser kalma; uydurmayı kısmen azaltmış, atıf doğruluğunu artırmamış
LegalCiteTrust (Li vd., 2026)	Çince; ağırlıklı olarak mevzuat atfı	72 uzun hukuk raporunda atıf güvenilirliği: varlık, sadakat, uygulanabilirlik	Resmî kaynaklardan erişilerek	Kısmen: "kısmen destekliyor", "aşırı genelleme", "ilgisiz" etiketleri; ayrı bir sınıf yok	Var: doğrulama sonuçlarının geri bildirimiyle LLM'e raporu yeniden yazdırma (rapor düzeyi). Kanıt alıntısı kontrolü, kalibrasyon ve çekimser kalma yok
TurkishLegalBench (Erkan ve Yozgatlıgil, ODTÜ, 2026)	Türkçe, yüksek mahkemeler	7 görev; TurkCite kanun no / madde no çıkarma, TurkCoherence gerekçe–hüküm NLI, TurkAudit zamansal uyumsuz atıf / halüsinasyon	Karar içi	Yok	—
HukukBERT (Öztürk, Türkoğlu ve Buz-Yalug, 2026)	Türkçe	Alan uyarlamalı hukuk dil modeli	—	—	—

Boşluk. Türkçe hukuk metinlerinde, dilekçedeki iddia ile atıf yapılan karar arasındaki destek ilişkisini ölçen bir veri seti bulunmamaktadır. Mevcut azaltma denemeleri ise ya yalnızca istemle çekimser kalmaya (LegalCiteBench) ya da rapor düzeyinde yeniden

yazmaya (LegalCiteTrust) dayanır; iddia düzeyinde kanıt gösterilmesini ve ölçülebilir bir eşikle çekimser kalınmasını birlikte sınayan bir yöntem bulunmamaktadır.

Tablodaki satırlar, çalışmaların tam metinleri (PARCEL, LegalCiteBench, LegalCiteTrust) ve resmî sayfaları (TurkishLegalBench, HukukBERT) ile karşılaştırılarak doğrulanmıştır (19 Ekim 2026).

- [x] ~~Her çalışmanın tam metni okunacak ve tablodaki ifadeler orijinaliyle karşılaştırılacak.~~
- [x] ~~TurkAudit ve TurkCoherence görevlerinin bu projeyle örtüşmediği TurkishLegalBench makalesinden teyit edilecek.~~

Ticari ürünler ve Türkçe değerlendirme çalışmaları

Taranan Türk hukuk yapay zekâ ürünlerinin hiçbiri, atıf yapılan kararın iddiayı destekleyip desteklemediğine dair bir doğruluk ölçümü yayımlamamaktadır. Türkçedeki tek açık atıf benchmark'ı (Legaluga) yalnızca künyenin var olup olmadığını ölçer.

Ürün / çalışma	Ne yapar	Atıf kontrolü	Yayımlanmış doğruluk ölçümü
Sinerji Hukuk Asistanı (Sinerji Yazılım; lansman 8 Eylül 2025)	Hukuki soru yanıtlama, dilekçe ve sözleşme taslağı; Mevzuat ve İçtihat programıyla birlikte	Tanıtımda atfın iddiayı desteklediğini kontrol eden bir özellik yok	Bulunamadı
Kılavuz	Dilekçe, araştırma, belge analizi; olay ile mevzuat arasında çelişki analizi	Kullandığı içtihadı kaynaklandırır; kontrolü kullanıcı yan panelde yapar	Rakiplerden yüksek doğruluk iddiası var; yöntem ve sayı yayımlanmamış
mevzuat.ai	11 milyonu aşkın kararda araştırma, dilekçe ve sözleşme taslağı	Her yanıtı dayandığı kaynakla verir	Bulunamadı
İçtiHub	Anlam temelli emsal arama, UYAP entegrasyonu, dilekçe taslağı	Kaynaklı ve atıflı çıktı	Bulunamadı
Lextum AI	Karar arama, dilekçe taslağı	İlgili kararlardan otomatik alıntı	Bulunamadı

Ürün / çalışma	Ne yapar	Atıf kontrolü	Yayımlanmış doğruluk ölçümü
Legaluga Law Benchmark (Legaluga ekibi, 2026; metodoloji)	Türk hukuku araştırma araçlarını aynı yapay zekâ ajanıyla karşılaştıran açık benchmark; 5 görev	Atıf denetimi görevi: dilekçedeki 5 künye için var / tarih hatalı / yok / belirsiz	Var; ancak yalnızca künyenin varlığı ölçülür, destek ilişkisi sınanmaz. Sinerji, Lexpera ve Kazancı açık API'leri olmadığı için teste alınmamıştır

Güncellenmiş boşluk. Bu projenin özgünlüğü, bu kontrolü yapan ilk araç olmak değildir. Özgünlük, destek ilişkisini ölçen ilk uzman etiketli Türkçe test seti ve bu sette yapılan ilk karşılaştırmalı ölçümdür. Legaluga'nın künye varlığını ölçen görevi ile bu proje birbirini tamamlar: biri "karar var mı?", diğeri "karar iddiayı destekliyor mu?" sorusunu ölçer.

Tarama 2 Kasım 2026'da ürünlerin herkese açık sayfaları üzerinden yapılmıştır. Ürünlerin yayımlamadığı iç ölçümleri olabilir; tablo yalnızca kamuya açık bilgiyi yansıtır.

- [ ] Ürün sayfalarının tarihli ekran görüntüleri arşivlenecek.
- [ ] Ürün listesi hukuk danışmanıyla tamamlanacak (Lexpera, Kazancı ve danışmanın bildiği diğer araçlar).
- [ ] Legaluga metodolojisinde anılan mecellem-legal-bench ve LawChatAI çalışmaları açılıp incelenecek.

3. Özgün bilimsel katkı

Projenin katkısı bir yazılım aracı değil, bir ölçümdür: Türkçe atıf doğrulamanın ne kadar güvenilir yapılabildiğini gösteren bir test seti, bu sette yapılan ilk ölçüm ve hatayı azaltan bir yöntem. Prototip ikincil bir çıktıdır. Sinerji gibi ticari araçlar projenin rakibi değil gerekçesidir: bu araçlar kullanılmaktadır, ancak bu görevdeki doğrulukları ölçülmemektedir.

1. **Türkçe iddia–karar test seti (ana çıktı).** İş hukuku Yargıtay kararları üzerinde "destekliyor / çelişiyor / yetersiz kanıt" olarak etiketlenmiş iddia–karar çiftleri. Test seti tamamen hukuk uzmanı onaylıdır. İncelenen Türkçe kaynaklarda (TurkishLegalBench ve Legaluga Law Benchmark dahil) destek ilişkisini ölçen bir veri seti bulunmamaktadır; bildiğimiz kadarıyla bu görev için Türkçe ilk test seti olacaktır. Set, lisans koşulları uygunsa açık paylaşılarak ticari araçlar dahil her sistemin bu görevde ölçülebileceği ortak bir ölçüt hâline gelir.

2. **İlk karşılaştırmalı ölçüm.** Ticari araçlarda da kullanılan temel yaklaşımların (benzerlik, BERT/NLI, LLM) bu sette ne sıklıkla yanlış destekleme yaptığı, hata türlerine göre ölçülür. İngilizce çalışmalardaki "kanıt yokluğunu fark etmek en zor durumdur" bulgusunun Türkçede de geçerli olup olmadığı sınanır.
3. **Kanıta dayalı seçici doğrulama (KSD).** Modelin gösterdiği kanıtın karar metninde gerçekten bulunup bulunmadığını ve modelin belirsizliğini birlikte değerlendiren, yeterli kanıt yoksa kesin karar vermekten kaçınan bir mekanizma (Bölüm 9). PARCEL'in gelecek çalışma olarak işaret ettiği yönü somut bir yönteme dönüştürür. LegalCiteTrust'taki revizyon yaklaşımından farkı, raporu yeniden yazmak yerine her iddia için ayrı karar vermesi, kanıtın birebir alıntıyla gösterilmesini zorunlu tutması ve emin olmadığında çekimser kalmasıdır.

4. Kapsam

Çalışma yalnızca iş hukukuna ve seçilmiş Yargıtay kararlarına odaklanır.

Kapsam içi

- Yargıtay'ın iş uyuşmazlıklarına bakan daire veya dairelerinin UYAP Emsal'de yayımlanmış kararları
- Tek bir iddia ile tek bir karar arasındaki destek ilişkisi
- Künyesi verilen kararın doğru karara eşleştirilmesi

Kapsam dışı (sonraki çalışmalar)

- Kararın güncelliği, HGK veya İBK ile aşılması ve kesinleşme durumu
- Diğer hukuk alanları ile Danıştay ve Anayasa Mahkemesi kararları
- Birden fazla kararın birlikte desteklediği iddialar
- UYAP'ın UDF belge biçimi desteği
- Ticari ürünlerin doğrudan test edilmesi (açık API bulunmaması ve kullanım koşulları nedeniyle); erişim ve izin sağlanırsa ek deney olarak eklenebilir

- [ ] Kapsama alınacak daireler ve konu başlıkları (ör. fazla mesai, kıdem tazminatı) hukuk danışmanıyla netleştirilecek.

5. Araştırma soruları ve hipotezler

Ana odak, desteklenmeyen hukuki iddiaların "destekliyor" olarak sınıflandırılmasını azaltmaktır. Bu hata, **yanlış destekleme oranı (YDO)** ile ölçülür: gerçek etiketi "çelişiyor" veya "yetersiz kanıt" olan örneklerden "destekliyor" olarak tahmin edilenlerin oranı. Tanım, PARCEL'deki False Entailment Rate ölçütünden uyarlanmıştır.

```
\mathrm{YDO} = P(\hat{y} = \text{destekliyor} \mid y \in \{\text{çelişiyor},
\text{yetersiz kanıt}\})
```

Araştırma soruları

1. Ticari araçlarda da kullanılan benzerlik, BERT/NLI ve LLM tabanlı yaklaşımlar, Türkçe Yargıtay kararlarında iddia–karar destek ilişkisini ne başarıyla sınıflandırır, ne sıklıkla yanlış destekleme yapar ve hangi hata türlerinde zorlanır?
2. Önerilen KSD mekanizması, YDO'yu Macro-F1'i belirgin biçimde düşürmeden azaltabilir mi?
3. Türkçe hukuk metinlerinde "yetersiz kanıt" sınıfı, "çelişiyor" sınıfından daha mı zordur?

Hipotezler

- **H1:** Metinsel benzerlik tabanlı yöntem, "yetersiz kanıt" sınıfında en yüksek YDO'yu üretir; çünkü metinsel benzerlik hukuki destekle aynı şey değildir.
- **H2:** KSD, en iyi temel yönteme eklendiğinde YDO'yu en az %30 göreli olarak azaltır ve Macro-F1 kaybı 2 puanı geçmez.
- **H3:** "Yetersiz kanıt" sınıfının F1 değeri, "çelişiyor" sınıfınınkinden düşüktür.

H2'deki eşikler ön hedeftir; pilot çalışmadaki temel değerlere göre gerekçelendirilerek kesinleştirilecektir.

6. Veri kaynakları, erişim ve ön çalışma

Birincil kaynak, kamuya açık UYAP Emsal Karar Arama sistemidir (emsal.uyap.gov.tr). Ön incelemede arama sonuçlarını JSON olarak döndüren bir sorgu uç noktası ve kararın tam metnini döndüren ayrı bir uç nokta tespit edilmiştir.

Erişim koşulları

- Sitenin kullanım koşulları incelenecek; gerekirse ilgili kurumdan yazılı izin istenecek.
- İstekler sınırlandırılacak (örneğin saniyede en fazla 1 istek) ve sunucuya yük bindirilmeyecek.
- Yalnızca kamuya açık, yayımlanmış karar metinleri kullanılacak. Kararlarda kalabilecek kişisel veri kalıntıları KVKK açısından kontrol edilecek.

Alternatif kaynaklar: TurkishLegalBench veri seti (Zenodo, DOI: 10.5281/zenodo.18555735) ve Yargıtay karar arama sistemi. TurkishLegalBench CC BY-NC-SA 4.0 lisansıyla dağıtılmaktadır: ticari olmayan kullanıma izin verir ve bu veriden türetilen veri setinin aynı lisansla paylaşılmasını şart koşar. Bu veri kullanılırsa projenin veri seti de aynı koşullarla paylaşılacaktır.

Ön çalışma (pilot). Yaklaşık 200 iş hukuku kararı programla indirilerek erişimin sürdürülebilirliği sınanacak. Ölçülecekler: başarılı indirme oranı, istek başına süre, metin biçimi ve paragraf ayrıştırma kalitesi.

Ölçüt	Sonuç
İndirilen karar sayısı	Pilot sonrası doldurulacak
Başarılı indirme oranı	Pilot sonrası doldurulacak
Ortalama istek süresi (sn)	Pilot sonrası doldurulacak
Tam metin biçimi	Pilot sonrası doldurulacak

- [ ] `emsal_ilk_deneme.py` çalıştırılıp pilot tablo doldurulacak.
- [ ] UYAP Emsal kullanım koşulları okunup bu bölüme özetlenecek.

7. Veri seti oluşturma ve uzman etiketlemesi

Hedef, yaklaşık 1.500 dengeli iddia–karar çifti ve bunun içinde tamamen uzman onaylı 300 örneklik bir test setidir. Bir kararın başka bir karara atıf yapması destek ilişkisi olduğu anlamına gelmediği için hiçbir etiket otomatik olarak "destekliyor" kabul edilmez.

Üç sınıfın üretimi

1. **Destekliyor:** Hukuk uzmanının karar metninden yazdığı iddialar ile kararlardaki atıf cümlelerinden alınıp uzmanca doğrulanan iddialar.
2. **Çelişiyor:** Destekleyen iddialardan hükmü tersine çevirme, koşul veya kapsamı değiştirme ve taraf veya madde değiştirme yoluyla türetilen iddialar (PARCEL'in stratejileri Türk hukukuna uyarlanarak).
3. **Yetersiz kanıt:** Aynı konudaki ama farklı sonuca varan bir kararla eşleştirilen iddialar, kararda bulunmayan bir ayrıntı eklenmiş iddialar ve kararda tartışılmamış bir argümana dayanan iddialar.

Dil modeliyle üretilen her aday örnek, veri setine girmeden önce insan tarafından kontrol edilir.

Etiketleme ve uzman doğrulaması

- Örneklerle bir etiketleme kılavuzu hazırlanır ve hukuk danışmanıyla onaylanır.
- Örneklerin %20'si iki etiketleyici tarafından bağımsız etiketlenir; uyum Cohen's kappa ile ölçülür, hedef ⩾ 0,70.
- Anlaşmazlıklar hukuk fakültesi öğretim üyesinin hakemliğiyle çözülür.
- Test setindeki her örnek uzman tarafından onaylanır.

- [ ] Hukuk fakültesi öğretim üyesi ve proje ortağı hukuk öğrencisinin durumu bu bölüme yazılacak.

8. Yöntem

Sistem, dilekçeden iddiayı çıkarıp ilgili kararın ilgili paragrafını bulur ve bu paragrafın iddiayı destekleyip desteklemediğine karar verir. Metinsel benzerlik yalnızca kanıt adayı bulmak için kullanılır; destek kararı ayrı bir çıkarım (NLI) adımıyla verilir.

1. **Künye ve iddia çıkarma:** Künyeler düzenli ifadelerle, düzensiz yazılmış olanlar dil modeliyle çıkarılır. İddia, atfın bağlı olduğu cümle veya cümle grubudur.
2. **Karar eşleştirme:** Künye UYAP Emsal'de aranır ve doğru karara eşlenir. Eşleştirme doğruluğu ayrıca ölçülür.
3. **Kanıt paragrafı bulma:** Karar paragraflara bölünür; kelime tabanlı (BM25) ve anlamsal (embedding) arama birleştirilerek iddiaya en ilgili ilk k paragraf seçilir.
4. **Destek sınıflandırma:** İddia ve kanıt paragrafları "destekliyor / çelişiyor / yetersiz kanıt" olarak sınıflandırılır.
5. **Doğrulama katmanı:** Sınıflandırma sonucu KSD mekanizmasından geçirilir (Bölüm 9).

Aday modeller

Görev	Aday modeller	Seçim gerekçesi
Anlamsal arama	Türkçe destekli çok dilli embedding modelleri	Türkçe hukuk metninde paragraf bulma; seçim pilot sonuçlarına göre
BERT/NLI sınıflandırıcı	BERTurk, HukukBERT	Türkçe ve Türk hukukuna uyarlanmış kodlayıcılar; Türkçe NLI verisiyle ön eğitim, ardından proje verisiyle ince ayar
LLM sınıflandırıcı	Bir açık ağırlıklı model ve bir ticari model	Zero-shot ve few-shot karşılaştırması; kanıt alıntısı üretebilme

- [ ] Her modelin adı, sürümü ve makalesi resmî sayfasından doğrulanıp kaynakçaya eklenecek.

9. Önerilen doğrulama mekanizması: Kanıta Dayalı Seçici Doğrulama (KSD)

KSD'de sistem "destekliyor" veya "çelişiyor" diyebilmek için iki şartı birlikte sağlamak zorundadır; biri sağlanmazsa kesin karar vermez ve "yetersiz kanıt, uzman kontrolü gerekli" çıktısı üretir.

1. **Kanıt varlığı kontrolü:** Sınıflandırıcı kararını, karar metninden bir kanıt alıntısıyla vermek zorundadır. Alıntı, normalleştirilmiş karar metninde birebir aranır. Bulunamazsa model kanıt uydurmuş sayılır ve karar geçersizdir.
2. **Belirsizlik kontrolü:** Model olasılıkları kalibre edilir (ör. temperature scaling) ve birden fazla model veya örneklemenin uyuşması ölçülür. Güven, eşik değeri τ'nun altındaysa karar verilmez.
3. **Çekimser kalma:** İki kontrolden biri başarısızsa çıktı "yetersiz kanıt" olur ve atıf uzmana yönlendirilir.

Eşik τ yalnızca doğrulama setinde seçilir ve test setinde sabit tutulur. Sonuçlar risk–kapsama eğrisiyle raporlanır: sistem daha az örnekte karar verdikçe hata oranının nasıl düştüğü gösterilir.

Gerekçe. LegalCiteBench, yalnızca istemle verilen "emin değilsen söyleme" talimatının atıf doğruluğunu artırmadığını göstermiştir. PARCEL ise modellerin kanıt yokken bile destek bulduğunu raporlamış ve doğrulayıcı ile belirsizlik temelli yaklaşımları gelecek çalışma olarak önermiştir. LegalCiteTrust'ta da yalnızca var olmayan atıfları ayıklamak, kalan karar atıflarının sadakat ve uygulanabilirliğini iyileştirmemiştir. KSD bu nedenle çekimser kalmayı istemle değil ölçülebilir iki kontrolle sağlar ve varlık kontrolüyle yetinmez.

LegalCiteTrust'taki revizyon yönteminden farkı. LegalCiteTrust, doğrulama sonuçlarını yapay zekâya geri bildirip raporu yeniden yazdırır ve başarıyı rapor düzeyinde ölçer. KSD ise her iddia için ayrı karar verir, kanıtın karar metninde birebir bulunmasını şart koşar, emin olmadığında karar vermeyip atfı uzmana yönlendirir ve etkisini yanlış destekleme oranı ile risk–kapsama eğrisi üzerinden ölçer.

10. Deney tasarımı ve başarı kriterleri

Dört yöntem aynı veri bölümleri ve aynı test seti üzerinde karşılaştırılır; KSD'nin katkısı, eklendiği yöntemin KSD'siz haliyle ayrıca kıyaslanarak ölçülür.

1. **Y1 – Benzerlik:** İddia ile en yakın paragraf arasındaki benzerliğe eşik uygulanır.
2. **Y2 – BERT/NLI:** İnce ayarlı BERTurk veya HukukBERT sınıflandırıcı.
3. **Y3 – LLM:** Zero-shot ve few-shot sınıflandırma.
4. **Y4 – Önerilen:** Y2 veya Y3'ten en iyisi + KSD.

Ölçüt	Tanım	Hedef
Macro-F1	Üç sınıfın F1 ortalaması	⩾ 0,75
Sınıf bazında precision / recall	Her sınıf için ayrı	Raporlanır
Yanlış destekleme oranı (YDO)	Bölüm 5'teki tanım; çelişiyor ve yetersiz kanıt için ayrı ayrı da	En iyi temel yönteme göre ⩾ %30 göreli azalma
Kapsama	Sistemin kesin karar verdiği örneklerin oranı	⩾ %80
Karar eşleştirme başarısı	Künyenin doğru karara eşlenme oranı	⩾ %95
İşlem süresi	10 atıflı bir dilekçe için	⩽ 60 sn

Hedefler ön hedeftir; pilot sonuçlarına göre gerekçelendirilerek güncellenecektir.

Deneylerin güvenilirliği

- Veri, kaynak karara göre gruplanarak eğitim / doğrulama / test (%70 / %15 / %15) olarak bölünür. Aynı karardan türetilen tüm çiftler tek bir bölümde kalır; böylece veri sızıntısı önlenir.
- Eşik ve hiperparametreler yalnızca doğrulama setinde seçilir; test seti tek bir kez, en sonda kullanılır.
- Eğitilen modeller 5 farklı rastgele tohumla çalıştırılır; ortalama ve standart sapma raporlanır.
- Farklar %95 bootstrap güven aralıkları ve McNemar testiyle sınanır.
- Hata analizi, Bölüm 7'deki üretim stratejilerine göre (hüküm tersine çevirme, eksik ayrıntı vb.) yapılır.

11. İş paketleri ve zaman planı

Proje 12 ayda altı iş paketiyle yürütülür; veri hazırlığı ve yöntem geliştirme kısmen paralel ilerler.

İP	İçerik	Ay	Çıktı	Başarı ölçütü
İP1	Literatür araştırması ve kaynak doğrulama	1–2	Doğrulanmış kaynak tablosu, literatür raporu	Her kaynak DOI veya resmî sayfadan doğrulanmış

İP	İçerik	Ay	Çıktı	Başarı ölçütü
İP2	Veri erişimi ve pilot çalışma	1–3	İş hukuku karar korpusu (~2.000 karar)	İndirme başarısı ⩾ %95; kullanım koşulları belgelenmiş
İP3	Veri seti oluşturma ve etiketleme	3–6	~1.500 iddia–karar çifti, 300 örneklik uzman onaylı test seti	Cohen's kappa ⩾ 0,70
İP4	Yöntem geliştirme (işlem hattı + KSD)	5–8	Çalışan işlem hattı ve KSD modülü	Doğrulama setinde uçtan uca çalışır
İP5	Karşılaştırmalı deneyler	8–10	Deney raporu ve hata analizi	H1–H3 test edilmiş, sonuçlar istatistiksel olarak raporlanmış
İP6	Prototip ve raporlama	10–12	Web prototipi, sonuç raporu, bildiri taslağı	Prototip bir dilekçeyi ⩽ 60 sn'de denetler

12. Risk yönetimi

En yüksek etkili iki risk veri erişimi ve etiketli veri yetersizliğidir; her ikisi için de pilot aşamasında erken uyarı alınır.

Risk	Olasılık	Etki	Alternatif çözüm
UYAP Emsal erişiminin kısıtlanması	Orta	Yüksek	Pilotta indirilen korpusla devam; TurkishLegalBench (lisans uygunsa) ve Yargıtay karar arama sistemi
Yeterli etiketli veri oluşturulamaması	Orta	Yüksek	Test setini 150 örneğe indirip çift etiketlemeyi korumak; eğitimde insan kontrollü sentetik örneklerin payını artırmak
Hukuk uzmanı desteği bulunamaması	Düşük–orta	Yüksek	Hukuk öğrencisi etiketleyici + danışman onaylı kılavuz; hakemliği daha dar bir alt kümeyle sınırlamak
Model başarısının düşük kalması	Orta	Orta	Kapsamı tek daire ve tek konuya daraltmak; olumsuz sonuçları da bilimsel bulgu olarak raporlamak
Hesaplama veya API maliyeti	Düşük	Orta	Küçük açık ağırlıklı modeller; maliyeti bütçede ayrı kalem olarak planlamak

13. Yaygın etki

Projenin kalıcı etkisi, Türkçe hukuk dil işleme alanına açık bir veri seti ve yöntem kazandırmasıdır.

- **Bilimsel:** Veri seti ve kod, lisans koşulları uygunsa açık olarak paylaşılır; sonuçlar ulusal bir konferansta bildiri olarak sunulur.
- **Mesleki:** Hukuk bürolarının ve baroların, kullandıkları yapay zekâ araçlarının atıf doğruluğunu ortak bir test setiyle sınayabilmesi; avukatların dilekçe vermeden önce atıflarını denetleyebilmesi.
- **Eğitim:** Hukuk fakültelerinde atıf ve içtihat kullanımı eğitimine destek; disiplinler arası (bilişim–hukuk) öğrenci iş birliği örneği.

14. Kaynak doğrulama beyanı ve kaynakça

Öneri hazırlanırken yapay zekâ aracından yazım ve yapılandırma desteği alınmıştır. Kaynakçadaki referanslar yayıncı veya resmî sayfalar üzerinden bulunmuş; literatür tablosundaki çalışmalar tam metinleri veya resmî sayfalarıyla karşılaştırılmıştır (19 Ekim 2026). Doğrulanamayan hiçbir kaynak nihai öneride yer almayacaktır.

İşaretli kutular, orijinal metni açılıp atıf yapılan bilgisi kontrol edilmiş kaynakları gösterir.

- [x] ~~Demir, M. M. ve Canbaz, M. A. (2026). When Citations Mislead? A Claim-Level Benchmark for Legal Hallucination Detection. *Proceedings of the 21st International Conference on Artificial Intelligence and Law (ICAIL 2026)*. DOI: 10.1145/3836937.3836948. arXiv · veri seti~~
- [x] ~~Chen, S., Yin, H. ve Zhou, S. (2026). LegalCiteBench: Evaluating Citation Reliability in Legal Language Models. arXiv:2605.10186. AI4Law Workshop, ICML 2026. arXiv · ICML sayfası~~
- [x] ~~Li, Y., Xie, M., Shi, Z., Wu, G. ve Yang, M. (2026). LegalCiteTrust: Benchmarking Citation Trustworthiness in Chinese Long-Form Legal Research Reports. arXiv:2607.20872. arXiv~~
- [x] ~~Erkan, M. A. ve Yozgatlıgil, C. (2026). TurkishLegalBench: A Comprehensive Multi-Task Benchmark Suite for Turkish Legal NLP [Veri seti]. Zenodo. DOI: 10.5281/zenodo.18555735. Lisans: CC BY-NC-SA 4.0. Hakemli bir makalesi henüz bulunamamıştır. AVESİS kaydı · GitHub~~
- [x] ~~Öztürk, M. U., Türkoğlu, T. ve Buz-Yalug, B. (2026). HukukBERT: Domain-Specific Language Model for Turkish Law. arXiv:2604.04790. arXiv · özet sayfası~~
- [x] ~~Legaluga ekibi (2026). Legaluga Law Benchmark: Türk hukuku araştırma araçları için açık benchmark [Yazılım ve veri]. GitHub. GitHub · Metodoloji~~
- [ ] Bölüm 8'de kullanılacak modellerin (BERTurk, embedding modelleri, LLM'ler) ve Türkçe NLI veri setlerinin kaynakları resmî sayfalarından eklenecek.